

APVC

Operações morfológicas
Convolução e filtros

Sumário


- Operações morfológicas
 - Dilatação e erosão
 - Abertura e fecho
 - Exemplos
- Convolução
 - Conceitos introdutórios
 - Convolução em imagens, passo-a-passo
 - Gradiente e detecção de contornos
 - Redução de ruído
 - Aumento da nitidez
 - Exemplos

Operações morfológicas

Operações morfológicas

- Operações não lineares que podem ser aplicadas tanto a imagens binárias (preto/branco) como a imagens em níveis de cinzento
- Quando aplicadas a imagens binárias:
 - remover ruído (e.g., remover ruído em máscaras "ruidosas")
 - preenchimento de "buracos" em regiões de pixels brancos (componentes conexos)
 - ...
- As operações morfológicas fazem uso de um “template”, designado por **elemento estruturante**, cujas dimensões são normalmente muito menores que as da imagem.
- As operações morfológicas elementares são a **erosão** e a **dilatação**.

Erosão






$$(I \ominus S)(x, y) = \begin{cases} 1 & \text{se } S \subseteq I \\ 0 & \text{caso contrário} \end{cases}$$

Resultado quando o elemento estruturante S se encontra centrado no pixel (x, y) da imagem:

- 1 – caso todos os pixéis da imagem estejam a '1' na zona de sobreposição com S (*i.e.*, o elemento estruturante "cabe" na zona de imagem que está a '1')
- 0 – quando há pelo menos um '0' da imagem sobreposto com S

Dilatação



$$(I \oplus S)(x, y) = \begin{cases} 1 & \text{se } I \cap S \neq \emptyset \\ 0 & \text{caso contrário} \end{cases}$$

Resultado quando o elemento estruturante S se encontra centrado no pixel (x,y) da imagem:

- 1 – quando existe pelo menos um pixel da imagem a ‘1’ na sobreposição com S
- 0 – quando todos os pixels da imagem sobrepostos com S estão a ‘0’

Dilatação e erosão – efeitos

■ Erosão

- “encolhe” os objetos
- remove objetos pequenos
- pode separar objetos



Imagem original



Binarização

■ Dilatação

- “alarga” os objetos
- preenche “buracos” no interior dos objetos
- objetos próximos podem ficar ligados



Dilatação



Erosão

Dilatação e erosão no OpenCV

- Definir um *elemento estruturante* – `getStructuringElement(...)`

Forma circular/elíptica

```
strel = cv2.getStructuringElement(cv2.MORPH_ELLIPSE, (7,7))
```

Forma quadrangular/rectangular

```
strel = cv2.getStructuringElement(cv2.MORPH_RECT, (5,5))
```

Forma de cruz

```
strel = cv2.getStructuringElement(cv2.MORPH_CROSS, (7,7))
```

Dimensões do elemento
estruturante (largura, altura)

- Aplicar dilatação ou erosão – `dilate(...)` e `erode(...)`

Dilatação

```
dilatedImg = cv2.dilate(img, strel)
```

Erosão

```
erodedImg = cv2.erode(img, strel)
```


Abertura e Fecho

- Operações morfológicas compostas
 - Abertura – Erosão seguida de dilatação
 - Remove ruído fora dos objetos e remove objetos pequenos
 - Pode também separar objetos (quando estão “pegados” através de ligações “finas”)
 - $I \circ S = (I \ominus S) \oplus S$
 - Fecho – Dilatação seguida de erosão
 - Remove ruído dentro dos objetos e preenche buracos no interior dos objetos
 - Pode juntar objetos que estejam próximos
 - $I \bullet S = (I \oplus S) \ominus S$

Abertura e Fecho no OpenCv

- Abertura

Abertura usando o elemento estruturante strel

```
imgOpened = cv2.morphologyEx(img, cv2.MORPH_OPEN, strel)
```

- Fecho

Fecho usando o elemento estruturante strel

```
imgClosed = cv2.morphologyEx(imgBin, cv2.MORPH_CLOSE, strel)
```



Imagem binária



Abertura



Fecho

Outras operações morfológicas

- Fronteiras (Gradiente morfológico)



Dilatação

-



Imagem binária

=



Gradiente morfológico

- Operações morfológicas sobre níveis de cinzento



Original




Dilatação



Erosão

Exemplo de utilização



Convolução

Convolução – Introdução

- Operação linear, muito importante em processamento de sinal
 - incluindo processamento de imagens!
- Em imagem, a convolução serve para diversas tarefas, entre as quais:
 - filtragem de ruído
 - estimação do gradiente (e, conseqüentemente, deteção dos contornos)
 - aumentar a nitidez / contraste
 - ...
- Mais à frente, vamos ver também que a convolução tem um papel muito importante na aprendizagem profunda (*deep learning*)
 - é uma operação fundamental nas redes neurais convolucionais (CNN's)

Convolução – Definição matemática

- Caso geral – convolução (*) entre um sinal s e um filtro (*kernel*) f

- Contínuo $(s * f)(x) = \int_{-\infty}^{+\infty} s(\tau)f(x - \tau)d\tau$

- Discreto $(s * f)(x) = \sum_{m=-\infty}^{\infty} s(m)f(x - m)$

- Caso específico das imagens

- Para simplificar assume-se que queremos realizar a convolução de uma imagem I com um filtro f (*kernel*) de dimensões $M \times N$ (com M e N ímpares)

$$(I * f)(x, y) = \sum_{m=-a}^a \sum_{n=-b}^b I(x + m, y + n)f(m + a, n + b) \quad a = \left\lfloor \frac{M}{2} \right\rfloor, b = \left\lfloor \frac{N}{2} \right\rfloor$$

Convolução passo-a-passo

-1	-1	-1	-1	-1	-1	-1
-1	1	-1	-1	-1	1	-1
-1	-1	1	-1	1	-1	-1
-1	-1	-1	1	-1	-1	-1
-1	-1	1	-1	1	-1	-1
-1	1	-1	-1	-1	1	-1
-1	-1	-1	-1	-1	-1	-1



1	-1	-1
-1	1	-1
-1	-1	1

$$\begin{aligned} &-1 \times 1 + -1 \times -1 + -1 \times -1 + \\ &-1 \times -1 + 1 \times 1 + -1 \times -1 + \\ &-1 \times -1 + -1 \times -1 + 1 \times 1 = \mathbf{7} \end{aligned}$$

7				

Para cada posição (x,y), centra-se o filtro nesse ponto; multiplicam-se ponto-a-ponto os coeficientes do filtro pelos valores de imagem correspondentes; o resultado da convolução será a soma dessas multiplicações

Convolução passo-a-passo

-1	-1	-1	-1	-1	-1	-1
-1	1	-1	-1	-1	1	-1
-1	-1	1	-1	1	-1	-1
-1	-1	-1	1	-1	-1	-1
-1	-1	1	-1	1	-1	-1
-1	1	-1	-1	-1	1	-1
-1	-1	-1	-1	-1	-1	-1



1	-1	-1
-1	1	-1
-1	-1	1

$$\begin{aligned} &-1 \times 1 + -1 \times -1 + -1 \times -1 + \\ &1 \times -1 + -1 \times 1 + -1 \times -1 + \\ &-1 \times -1 + 1 \times -1 + -1 \times 1 = -1 \end{aligned}$$

7	-1			

Vai-se deslizando o filtro por todas as posições possíveis e aplicando as multiplicações / soma.

Convolução passo-a-passo

-1	-1	-1	-1	-1	-1	-1
-1	1	-1	-1	-1	1	-1
-1	-1	1	-1	1	-1	-1
-1	-1	-1	1	-1	-1	-1
-1	-1	1	-1	1	-1	-1
-1	1	-1	-1	-1	1	-1
-1	-1	-1	-1	-1	-1	-1

*

1	-1	-1
-1	1	-1
-1	-1	1

=

7	-1	3	-1	3
-1	9	-3	1	-1
3	-3	5	-3	3
-1	1	-3	9	-1
3	-1	3	-1	7

O resultado final da convolução obtém-se deslizando o filtro por todas as posições possíveis na imagem. A não ser que se utilize *padding* (i.e., acrescentar artificialmente linhas/colunas à imagem), as dimensões da matriz do resultado são inferiores às da imagem, dado que não se consegue encaixar o filtro nos pontos situados nas bordas da imagem.


Convolução passo-a-passo

-1	-1	-1	-1	-1	-1	-1
-1	1	-1	-1	-1	1	-1
-1	-1	1	-1	1	-1	-1
-1	-1	-1	1	-1	-1	-1
-1	-1	1	-1	1	-1	-1
-1	1	-1	-1	-1	1	-1
-1	-1	-1	-1	-1	-1	-1

*



1	-1	-1
-1	1	-1
-1	-1	1

=



O resultado da convolução pode ser visualizado como uma imagem, normalizando os valores para a gama de 0...255

Resultados da convolução com outros kernels



Convolução no OpenCV

- Embora existam mais possibilidades, a forma mais genérica de realizar a convolução é usando a função `filter2D(...)`

definição de um filtro (neste caso é um filtro de média)

```
meanKernel = np.array(  
    [1, 1, 1],  
    [1, 1, 1],  
    [1, 1, 1]), dtype=np.float32) / 9
```

aplicar a convolução com o filtro definido à imagem img

```
filteredImg = cv2.filter2D(img, None, meanKernel)
```

Nota: o 2º parâmetro da função pode ser usado para indicar o formato numérico do output

usar '-1' ou 'None' significa que o formato numérico do output será o mesmo que o da imagem de input

Algumas aplicações da convolução

Gradiente e detecção de contornos

-1	0	1
-2	0	2
-1	0	1


Convolução com *kernel de Sobel*
segundo direção horizontal
-> componente x do gradiente (G_x)



Imagem original

-1	-2	-1
0	0	0
1	2	1

Convolução com *kernel de Sobel*
segundo direção vertical
-> componente y do gradiente (G_y)



Gradiente de imagem (∇I):
Derivadas ao longo das direções
horizontal e vertical

$$\nabla I = \begin{bmatrix} \frac{\partial I}{\partial x} \\ \frac{\partial I}{\partial y} \end{bmatrix} = \begin{bmatrix} G_x \\ G_y \end{bmatrix}$$

Gradiente e detecção de contornos

Magnitude do gradiente




$$G_{mag} = \sqrt{G_x^2 + G_y^2}$$

Binarização (Otsu)



Algoritmo de *Canny*



Aumentar a nitidez de imagens (*Sharpen*)





Imagem original



Convolução com o seguinte *kernel*:

0	-1	0
-1	5	-1
0	-1	0

Redução de ruído



Imagem com ruído



Convolução com *kernel* gaussiano 3x3

$$\begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix} \times \frac{1}{16}$$

Redução de ruído



Imagem com ruído



Convolução com *kernel* gaussiano 3x3

$$\begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix} \times \frac{1}{16}$$


Extras

Binarização – Método de Otsu

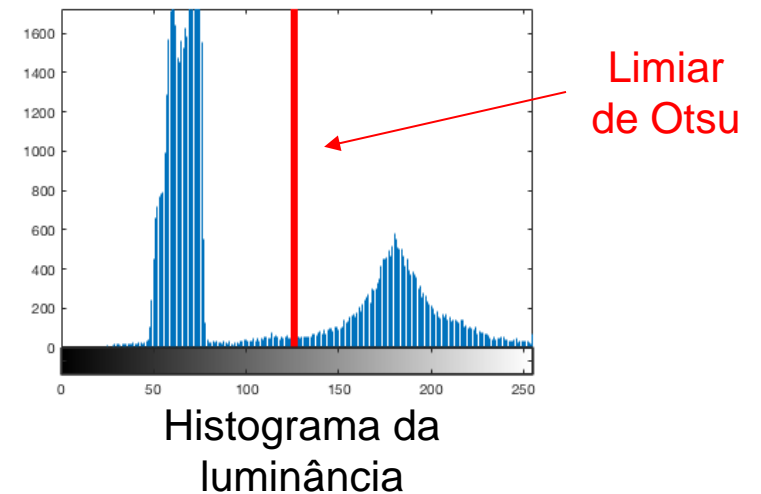
- Método adaptativo onde o valor de limiar (*threshold*) para binarização é obtido automaticamente
 - Assume que existem duas zonas (classes) na imagem – *foreground* e *background* – com características distintas nos valores de luminância (ou numa componente da cor)
 - O valor de limiar obtido corresponde ao valor que separa as classes minimizando a *variância intra-classe* dos valores dos pixels



Imagem original (lum.)



Binarização (Otsu)



- No OpenCV:

```
img = cv2.imread("images/think.jpg", cv2.IMREAD_GRAYSCALE)
(t, imgBin) = cv2.threshold(img, 0, 255, cv2.THRESH_OTSU)
```

OpenCV – Componentes conexos

Para obter estatísticas sobre as várias regiões a branco (*componentes conexos*) que estão presentes numa imagem binária (imgBin) pode-se utilizar:

```
(numLabels, labels, boxes, centroids) = cv2.connectedComponentsWithStats(imgBin)
```

Significado:

- numLabels – número de componentes conexos
- labels – Id's dos componentes
- boxes – *bounding boxes* - coordenadas do canto superior esquerdo, altura e largura dos retângulos envolventes
- centroids – coordenadas dos centróides dos componentes conexos

OpenCV – Convoluções “especializadas”

O OpenCV inclui diversas funções que realizam convoluções “especializadas”, onde não é necessário definir o *kernel*. Exemplos:

blur – aplica um filtro de média com as dimensões indicadas

```
filtered = cv2.blur(img, (5,5))
```

GaussianBlur – aplica um filtro gaussiano com as dimensões indicadas

```
filtered = cv2.GaussianBlur(img, (5,5))
```

Sobel – aplica um filtro de Sobel na direção indicada

```
Gx = cv2.Sobel(img, -1, dx=1, dy=0)
```

```
Gy = cv2.Sobel(img, -1, dx=0, dy=1)
```

...

OpenCV – Formatos numéricos em `filter2D(...)`

Por vezes é necessário ter cuidado com o formato numérico resultante de uma convolução com `filter2D(...)`

Assumindo uma imagem `img` com valores inteiros na gama `[0, 255]`, o formato numérico correspondente é 8 bits sem sinal – `np.uint8` (numpy) ou `cv2.CV_8U` (OpenCV)

Ao realizarmos

```
filtered = cv2.filter2D(img, None, kernel)
```

o parâmetro da função a `None` (ou a `-1`) faz com que o formato numérico do resultado seja igual ao de `img`.

Assim, todos os valores resultantes que calhassem fora de `[0, 255]` ficariam saturados em 0 ou 255, consoante fossem menores que 0 ou superiores a 255, respetivamente.

Mas em muitas situações pretendem-se obter os valores reais do resultado, e não valores restringidos a `[0, 255]`. Para isso será necessário especificar um formato numérico apropriado no 2º parâmetro da função:

```
filtered = cv2.filter2D(img, cv2.CV_32F, kernel)
```

Neste caso o resultado seria dado numa matriz de *floats* de 32 bits (`cv2.CV_32F`, equivalente a `np.float32`), permitindo obter os valores reais do resultado e sem restrições à gama `[0, 255]`

OpenCV – Visualização de matrizes

Em processamento de imagem é muito habitual visualizarmos uma matriz 2D que na realidade não é uma imagem, pois não tem valores de pixel entre 0 e 255 (por exemplo, visualizar a magnitude do gradiente)

Nessas situações, para visualizar o conteúdo de uma matriz `mat` usando `imshow(...)`, é necessário normalizar primeiro os seus valores, de modo a que estes fiquem na gama `[0, 255]` (inteiros) ou então na gama `[0, 1.0]` (reais)

Para realizar essa tarefa pode-se usar a função `normalize(...)` do openCV:

```
mat_norm= cv2.normalize(mat, None, 0, 255, cv2.NORM_MINMAX, cv2.CV_8U) # normaliza para [0, 255], inteiros
```

```
mat_norm= cv2.normalize(mat, None, 0, 1.0, cv2.NORM_MINMAX, cv2.CV_32F) # normaliza para [0, 1.0], float  
cv2.imshow("Visualização de mat", mat_norm)
```

Noutras ocasiões, quando se sabe *a priori* que a matriz contém apenas valores positivos ou a zero, para normalizar na gama `[0, 1.0]` basta dividir todos os valores pelo valor máximo:

```
mat_norm = mat / mat.max()  
cv2.imshow("Visualização de mat", mat_norm)
```

Recursos

- Imagens

- “Think”, <https://unsplash.com/s/photos/text>
- “Damas”, <https://www.amazon.com/Basic-Checker-Set-Made-USA/dp/B001PF83HG>
- “Lenna”, <https://en.wikipedia.org>
- “A persistência da memória, Dali”, <https://www.culturagenial.com/a-persistencia-da-memoria-de-salvador-dali/>
- “Castelo Neuschwanstein”, <https://www.euronews.com/travel/2021/06/28/14-castles-in-europe-that-are-straight-out-of-a-fairy-tale>
- Método de Otsu, <https://blogs.mathworks.com/steve/2016/06/14/image-binarization-otsus-method/>

- Tutoriais opencv python

- GeekforGeeks - <https://www.geeksforgeeks.org/opencv-python-tutorial/>
- LearnOpenCV - <https://learnopencv.com/getting-started-with-opencv/>
- Pyimagesearch – <https://www.pyimagesearch.com/>

- Kenneth Dawson-Howe, *A Practical Introduction to Computer Vision with OpenCV*, Wiley, 2014